

MODELOS LINEALES II: TRABAJO PRÁCTICO

Aida Bravo Muñoz (1638308) Lucas Poveda Estrada (1597330)
Roc Grau Piqué (1563847)

2024-12-19

PREPARACIÓN DE DATOS

Primero de todo, comenzamos cargando los datos. Nuestros datos representan las alturas de diferentes niños a lo largo de su edad.

```
load("Oxboys.Rda")
summary(Oxboys)
sapply(Oxboys,class)
Oxboys$Occasion<-as.numeric(Oxboys$Occasion)
```

```
##      Subject      age      height      Occasion
##  10      :  9  Min.    :-1.00000  Min.    :126.2   1      :26
##  26      :  9  1st Qu.: -0.46300  1st Qu.:143.8   2      :26
##  25      :  9  Median  :-0.00270  Median :149.5   3      :26
##   9      :  9  Mean    : 0.02263  Mean    :149.5   4      :26
##   2      :  9  3rd Qu.: 0.55620  3rd Qu.:155.5   5      :26
##   6      :  9  Max.    : 1.00550  Max.    :174.8   6      :26
## (Other):180                                (Other):78
## $Subject
## [1] "ordered" "factor"
##
## $age
## [1] "numeric"
##
## $height
## [1] "numeric"
##
## $Occasion
## [1] "ordered" "factor"
```

En este estudio podemos observar como se han recogido de 26 chicos sus alturas en 9 ocasiones diferentes. Por lo tanto, nuestros datos contienen 3 variables recogidas en el experimento: “**Subject**” referente al niño (unidad experimental); “**height**”, la altura del individuo medida en centímetros (variable de interes por lo que será nuestra variable respuesta); y, “**age**”, edad estandarizada de los sujetos (variable explicativa recogida en el experimento).

Observamos en la variable referente a la edad que los intervalos de tiempo no son equidistantes, se han recogido en diversos intervalos, por lo que las diferencias de alturas de una medida a la siguiente han sido recogidas con diferentes cantidades de tiempo entre si (algunas han pasado 9 meses, otras 11, otras un año...). El experimetador ha decidido añadir la variable “occasion” la cual identifica el orden en que se han tomado

las medidas sin evidenciar la cantidad de tiempo que ha pasado entre medidas, permitiendo hacer un análisis donde las medidas son equidistantes. Esta variable esta recogida como factor, indicando el orden en el que se han tomado las medidas, numeradas del 1 al 9. La transformaremos a numérica para realizar un análisis longitudinal, que no tenga en cuenta las diferencias en los periodos de recogida de los datos, (intervalos equidistantes).

Una vez explicadas nuestras variables nos centramos en observar como se distribuyen para conocer más con que tipo de datos vamos a trabajar.

```
with(Oxboys, by(height, age, summary))
```

```
## age: -1
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  126.2  138.2   143.3   143.1  147.7   156.9
## -----
## age: -0.7479
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  128.2  139.3   144.9   144.6  148.4   158.7
## -----
## age: -0.715
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  149.8  149.8   149.8   149.8  149.8   149.8
## -----
## age: -0.463
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  129.0  142.8   147.0   146.7  150.9   160.6
## -----
## age: -0.4493
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  135.3  139.8   144.3   142.8  146.5   148.7
## -----
## age: -0.1643
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  129.4  143.3   148.8   148.1  152.2   163.3
## -----
## age: -0.0027
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  129.6  143.8   148.8   147.9  152.1   164.4
## -----
## age: 0
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  146.1  154.1   157.9   156.4  160.3   163.8
## -----
## age: 0.2466
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  130.6  146.0   151.6   150.5  155.4   167.3
## -----
## age: 0.5562
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  132.5  147.9   153.5   152.7  157.0   170.7
## -----
## age: 0.7781
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  133.4  150.5   156.6   156.0  160.9   172.4
```

```
## -----
## age: 0.7808
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   142.7  142.7   142.7   142.7   142.7   142.7
## -----
## age: 0.7945
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   143.7  147.1   150.5   149.4   152.3   154.1
## -----
## age: 0.9945
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   134.2  151.8   156.8   156.8   162.4   174.8
## -----
## age: 0.9973
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   158.7  158.7   158.7   158.7   158.7   158.7
## -----
## age: 1.0055
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   143.1  146.1   149.0   149.0   151.9   154.9
```

En primer lugar podemos observar como se distribuye la variable correspondiente a la altura, en función de la edad estandarizada basándonos en el resumen estadístico que se muestra previamente. Podemos observar que no siguen un crecimiento lineal a simple vista; es decir, desde la edad más baja hasta el niño más mayor las alturas no van incrementando de manera lineal, si no que suben y bajan o se estacan. Esto se debe al hecho de que estas medidas no se han tomado en las mismas edades para todos los niños. A hacer una tabla con las alturas recogidas en los diferentes tipos de edades que tenemos obtenemos lo siguiente:

```
table(Oxboys$age)
```

```
##
##      -1 -0.7479 -0.715 -0.463 -0.4493 -0.1643 -0.0027      0  0.2466  0.5562
##      26      25      1      23      3      26      22      4      26      26
## 0.7781 0.7808 0.7945 0.9945 0.9973 1.0055
##      22      1      3      23      1      2
```

En esta podemos presenciar el hecho de que por ejemplo en la edad estandarizada -0.715, solo obtenemos una observación, únicamente la altura de un sujeto se midió en ese momento (así como 0.7808 o 0.9973). En cambio hay edades en las que se midió exactamente a los 26 niños del estudio, edades como -1, -0.1643, 0.2466 o 0.5562. Esto hace que mediante el resumen estadístico anterior se complique encontrar alguna relación.

Por otro lado, tenemos la variable “**occasion**”, creada por el experimentador a partir de la variable “**age**” para crear intervalos de tiempo equidistantes.

```
with(Oxboys, by(height, Occasion, summary))
```

```
## Occasion: 1
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   126.2  138.2   143.3   143.1   147.7   156.9
## -----
## Occasion: 2
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   128.2  140.1   145.0   144.8   148.7   158.7
```

```
## -----
## Occasion: 3
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   129.0   141.8   146.3   146.2   150.2   160.6
## -----
## Occasion: 4
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   129.4   143.3   148.8   148.1   152.2   163.3
## -----
## Occasion: 5
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   129.6   144.7   149.6   149.2   154.1   164.4
## -----
## Occasion: 6
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   130.6   146.0   151.6   150.5   155.4   167.3
## -----
## Occasion: 7
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   132.5   147.9   153.5   152.7   157.0   170.7
## -----
## Occasion: 8
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   133.4   150.2   155.6   154.8   159.2   172.4
## -----
## Occasion: 9
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   134.2   151.8   156.3   156.3   161.3   174.8
```


Al contrario que en el caso anterior, mediante este resumen estadístico sí que podemos observar que a medida que va pasando el tiempo o las ocasiones, de media los niños crecen. Podemos observar que desde la primera medida hasta la última los niños de media crecen 13 centímetros aproximadamente. Esto se debe a que tal y como ya hemos comentado, la siguiente tabla nos muestra que en cada ocasión se han recogido exactamente las 26 alturas de los diferentes sujetos.

```
table(Oxboys$Occasion)
```

```
##
##  1  2  3  4  5  6  7  8  9
## 26 26 26 26 26 26 26 26 26
```


Otra herramienta útil que nos hace conocer mejor como son estas variables con las que queremos y vamos a trabajar es mediante gráficos. Por ello, a continuación, podemos presenciar un *pairs*, una matriz de gráficos de dispersión, de nuestras variables reflejando la relación entre ellas.

```
pairs(Oxboys)
```




Cabe destacar la relación positiva entre la edad estandarizada, “age” y “height”, la altura, ya que a medida que aumenta la edad estandarizada, la altura tiende a crecer de manera lineal, confirmando una tendencia de crecimiento progresiva (todo y que con el resumen estadístico previo no se haya podido observar esta relación con detalle). Lo mismo sucede con la variable “age” y “occasion”, presentando también una relación creciente. No obstante, debemos tener en cuenta que esta última variable “occasion”, es originada a partir de “age”. Por último, otro detalle importante a destacar es como cada sujeto parece presentar su propia trayectoria de crecimiento, sugiriendo variabilidad interindividual, diferencia en las alturas y patrones de crecimiento entre distintos niños. Este aspecto se puede comentar a mayor rasgo en el siguiente gráfico, creado, especialmente, para poder visualizar esto último en detalle.

```
ggplot(Oxboys, aes(x = Occasion, y = height, color = Subject, group = Subject)) +
  geom_line() + # Líneas
  labs(title = "Altura por Ocasión",
       x = "Ocasión",
       y = "Altura",
       color = "Sujeto") + # Títulos y etiquetas
  theme_minimal()
```



Y, efectivamente, en este segundo gráfico podemos confirmar como cada sujeto, representado por un color diferente, tiene una trayectoria única respecto su altura. No únicamente son diferentes y únicas sus alturas iniciales, si no también las pendientes; es decir, el recorrido de su crecimiento a lo largo de las diferentes ocasiones.

```
par(mfrow=c(1,2))
plot(height~age+Occasion,Oxboys)
title("Altura en función de 'age' y 'occasion'",
      outer = TRUE, line = -1.5, cex = 1.5)
```



Por un lado, mediante el gráfico de la izquierda podemos observar que para cada cada nivel de “age”, hay una amplia variabilidad en la altura, lo que indica diferencia en el crecimiento entre los sujetos. Por otro lado, las medianas de “height” aumentan progresivamente con “Occasion”, indicando que las ocasiones representan momentos consecutivos de medición y que lo sujetos crecen de manera constante. Además, se puede observar como a medida que los sujetos crecen, las diferencias individuales en altura se hacen más evidentes, ya que los rangos intercuartílicos y bigotes aumentan progresivamente también. Cabe destacar la presencia de algunos valores atípicos en las primeras y últimas ocasiones, representando mediciones excepcionales, sujetos con un patrón de crecimiento distinto.

Una vez analizados los resúmenes estadísticos de las diferentes variables, así como visualizadas sus distribuciones mediante diversos gráficos podemos deducir que sería adecuado ajustar un **modelo mixto** con efectos fijos para la edad estandarizada y la ocasión, y efectos aleatorios como por ejemplos un intercepto aleatorio para sujeto.

MODELADO



Nuestro estudio consiste en la elaboración de un modelo orientado a la comprensión de los datos, sin buscar una capacidad predictiva especial. Hemos elaborado diversos modelos para posteriormente compararlos y seleccionar el más óptimo. No obstante, antes de todo realizamos dos gráficos más que nos hagan comprobar como, tal y como hemos comentado en la preparación de los datos, que los sujetos tienen trayectorias únicas respecto sus alturas; es decir, que cada sujeto empieza con una altura única y esta altura es modificada a lo largo del tiempo de manera única tambien.

```
xyplot(height ~ age|Subject,
      data = Oxboys,
```

```

type="o")
xyplot(height ~ Occasion|Subject,
data = Oxboys,
type="o")

```



En estos dos gráficos podemos comprobar varios detalles. El primero, efectivamente, las variables respecto la edad y la ocasión parecen ser la misma variable pero tomando los intervalos de tiempo equidistantes o no. En segundo lugar, observamos como cada sujeto empieza en un punto diferente; es decir, la altura base de los niños es única, haciéndonos pensar en la inclusión de un intercepto aleatorio a nuestros futuros modelos. Finalmente, cada individuo al fijarnos sus diferentes alturas medidas a lo largo de la edad o a lo largo de las ocasiones, parecen tener trayectorias únicas; es decir, crecen de manera individual a lo largo de las edades y ocasiones, no crecen lo mismo.

Por lo tanto, dada la estructura de los datos, tenemos una variable respuesta de interés (la altura) medida para 26 sujetos diferentes (las unidades experimentales). Estas mediciones se han realizado en 9 situaciones diferentes para todos los individuos, en diferentes momentos recogidos en la variable explicativa (la edad). A partir de esta variable, se ha elaborado una segunda variable explicativa (la ocasión) para poder realizar dos tipos de estudio:

- Uno a través de la variable edad, contemplando la heterogeneidad en los intervalos entre mediciones.
- Y otro a través de la variable ocasión, donde los intervalos se suponen homogéneos.

Puesto que las dos variable recogen el mismo fenomeno (el tiempo), y una se ha construido a partir de la otra, las variables no son independientes entre si, cosa que ya sospechabamos mediante los gráficos cuando hemos estudiado la distribución de nuestras variables. Esto lo podemos comprobar calculando su correlacion:

```
cor.test(Oxboys$age, Oxboys$Occasion)

##
## Pearson's product-moment correlation
##
## data: Oxboys$age and Oxboys$Occasion
## t = 321.42, df = 232, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.9985495 0.9991338
## sample estimates:
## cor
## 0.9988791
```

Tal y como podemos observar tienen una correlación de 0.9988791, muy próxima a 1, indicando así que, efectivamente, estan muy correlacionadas, hecho que tiene sentido porque una es creada a partir de otra. No es completamente uno precisamente por los intervalos homogeneos y heterogeneos que las diferencian, pero si que son la misma variable. Esto descarta un modelo que incluya a ambas, como comprobamos a continuación.

En este primer modelo incluimos ambas variables de manera aditiva, ya que realmente ambas variables han sido creadas por el experimentador por interés clasificándolas como efectos fijos. Al incluir ambas, podremos observar como de bueno o malo es incluir las dos. Además, incluimos un intercepto aleatorio para cada sujeto, definiendo así los efectos aleatorios para poder controlar la variabilidad de que cada niño es único, cada niño empieza con una altura base única. Este modelo se expresa de la siguiente manera:

$$\text{height}_{ij} = \beta_0 + \beta_1 \cdot \text{age}_i + \beta_2 \cdot \text{Occasion}_i + u_j + \epsilon_{ij}$$

Donde:

- height_{ij} : Altura del sujeto j en la ocasión i .
- β_0 : Intercepto fijo.
- β_1 : Efecto fijo asociado a la variable `age`.
- β_2 : Efecto fijo asociado a la variable `Occasion`.
- u_j : Efecto aleatorio del sujeto j , donde $u_j \sim N(0, \sigma_u^2)$, intercepto aleatorio para cada sujeto.
- ϵ_{ij} : Error residual, donde $\epsilon_{ij} \sim N(0, \sigma^2)$.

```
# Comprobamos la significancia de las variables que componen los efectos fijos
# Modelo 1 (con ambas variables, aditivo):
mod1 <- lmer(height~age + Occasion + (1|Subject), Oxboys)
summary(mod1)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: height ~ age + Occasion + (1 | Subject)
## Data: Oxboys
```



```
##
## REML criterion at convergence: 937
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.2480 -0.6250 -0.1466  0.6237  2.4503
##
## Random effects:
##   Groups   Name      Variance Std.Dev.
##   Subject (Intercept) 65.55    8.096
##   Residual              1.71    1.308
## Number of obs: 234, groups: Subject, 26
##
## Fixed effects:
##              Estimate Std. Error      df t value Pr(>|t|)
## (Intercept) 144.5741      3.7872 220.4209  38.175  <2e-16 ***
## age          2.6261      2.7957 206.0020   0.939   0.349
## Occasion      0.9772      0.7001 206.0020   1.396   0.164
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##          (Intr) age
## age          0.907
## Occasion -0.908 -0.999
```

En este primer modelo podemos observar que al incluir dos variables prácticamente iguales, la misma variable dos veces, ninguna de ellas es significativa. Para que esto no suceda, realizaremos modelos diferentes para estas dos variables.

Comparamos los modelos para cada una de ellas para estudiar si el modelo con intervalos homogéneos **occasion** (el que se elaboró a posteriori para estudiar este fenómeno en concreto) funciona mejor que el de intervalos heterogéneos AGE (el que se recogió en el experimento). Por lo tanto tendremos dos tipos de conjunto de modelos, un conjunto de modelos con la variable **age** como efecto fijo, y otro conjunto, con la variable **occasion** como efecto fijo. Dentro de cada conjunto variarán los efectos aleatorios (con intercepto aleatorio pero sin pendiente, con intercepto aleatorio y pendiente sin estar ambos correlacionados y con intercepto aleatorio y pendiente estando ambos correlacionados). En total, se realizarán seis modelos diferentes.

• Primer modelo

En primer lugar nos centraremos en tener la variable **age** (intervalos heterogéneos) como efecto fijo. Respecto los efectos aleatorios, tenemos únicamente el intercepto aleatorio asociado a cada sujeto, indicando que cada sujeto empieza con una altura única. Este modelo se expresa de la siguiente manera:

$$\text{height}_{ij} = \beta_0 + \beta_1 \cdot \text{age}_i + u_{0j} + \epsilon_{ij}$$

Donde,

- β_0 : Intercepto fijo.
- β_1 : Efecto fijo de **age**.
- u_{0j} : Efecto aleatorio del intercepto para el sujeto j , donde $u_{0j} \sim N(0, \sigma_{u0}^2)$.
- ϵ_{ij} : Error residual, donde $\epsilon_{ij} \sim N(0, \sigma^2)$.

```

# MODELO 1
# Efecto fijo: age
# Efecto aleatorio: intercepto aleatorio por cada sujeto
mod1 <- lmer(height ~ age + (1|Subject), Oxboys)
summary(mod1)

## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: height ~ age + (1 | Subject)
## Data: Oxboys
##
## REML criterion at convergence: 940
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.1857 -0.6350 -0.1339  0.6252  2.5357
##
## Random effects:
## Groups Name Variance Std.Dev.
## Subject (Intercept) 65.555  8.097
## Residual 1.718  1.311
## Number of obs: 234, groups: Subject, 26
##
## Fixed effects:
## Estimate Std. Error df t value Pr(>|t|)
## (Intercept) 149.3717 1.5902 25.0002 93.93 <2e-16 ***
## age 6.5239 0.1325 207.0000 49.23 <2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
## (Intr)
## age -0.002

```

Al realizar el resumen del modelo podemos observar diferentes detalles, entre ellos que la varianza del intercepto aleatoria para el grupo **Subject** es 65.555, lo que indica diferencias significativas en los niveles iniciales de altura entre sujetos. Además, podemos observar que el efecto fijo de age es positivo y significativo, indicando que la altura aumenta linealmente con la edad.

• Segundo modelo

En el segundo modelo, continuamos con la variable referente a la edad como efecto fijo. No obstante, modificamos los efectos aleatorios. En este caso, seguimos contando con un intercepto aleatorio para cada sujeto, pero, además, incluimos la pendiente aleatoria según edad, indicando que las alturas a lo largo de las edades para los sujetos son diferentes. En este modelo estos dos términos que componen los efectos aleatorios no están correlacionados, por lo que el hecho de que las alturas bases para los sujetos sean únicas serán independientes a que también sus trayectorias lo sean. El segundo modelo estudiado se expresa de la siguiente manera:

$$\text{height}_{ij} = \beta_0 + \beta_1 \cdot \text{age}_i + u_{0j} + u_{1j} \cdot \text{age}_i + \epsilon_{ij}$$

Donde,

- β_0 : Intercepto fijo.

- β_1 : Efecto fijo de age.
- u_{0j} : Efecto aleatorio del intercepto para el sujeto j , donde $u_{0j} \sim N(0, \sigma_{u0}^2)$.
- u_{1j} : Pendiente aleatoria no correlacionada con age, donde $u_{1j} \sim N(0, \sigma_{u1}^2)$.
- ϵ_{ij} : Error residual, donde $\epsilon_{ij} \sim N(0, \sigma^2)$.

```
# MODELO 2
# Efecto fijo: age
# Efecto aleatorio: intercepto aleatorio + pendiente aleatoria (no correlacionados)
mod2 <- lmer(height ~ age + (1|Subject) + (0 + age|Subject) , Oxboys)
summary(mod2)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: height ~ age + (1 | Subject) + (0 + age | Subject)
## Data: Oxboys
##
## REML criterion at convergence: 736.6
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.64258 -0.56700 -0.01326  0.61132  2.64272
##
## Random effects:
## Groups      Name                Variance Std.Dev.
## Subject    (Intercept)  65.3192   8.0820
## Subject.1 age           2.8255   1.6809
## Residual                    0.4354   0.6599
## Number of obs: 234, groups: Subject, 26
##
## Fixed effects:
##              Estimate Std. Error      df t value Pr(>|t|)
## (Intercept) 149.3717    1.5856   25.0000   94.2   <2e-16 ***
## age         6.5254     0.3363   24.9984   19.4   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##      (Intr)
## age 0.000
```

En este caso, el resumen nos muestra que la altura aumenta en aproximadamente 6.52 cm por cada unidad de incremento en la edad estandarizada. Además, hay variabilidad significativa en los interceptos entre sujetos, y las pendientes de también varían entre sujeto, aunque no están correlacionadas con el intercepto. Debemos comentar que en este caso, el modelo explica gran parte de la variabilidad en los datos, dejando solo 0.4354 de varianza residual.

• Tercer modelo

Como tercer modelo, continuaremos con la edad estandarizada como efecto fijo; así como con los interceptos aleatorios para cada sujeto y las pendientes. No obstante, en este modelo, ambos términos que representan los efectos aleatorios están correlacionados. Este modelo recogerá, por lo tanto, la interacción entre los β_0 asociados al sujeto en cuestión, y los β_1 asociados a este sujeto en su evolución temporal (la pendiente).

Permitirá recoger relaciones que hemos podido vislumbrar en los plots iniciales, como la del sujeto 10, el más bajito al inicio del experimento, que es también el que menos crece a lo largo del experimento. Sin embargo, los sujetos 19 o 13 por ejemplo, que al inicio del experimento eran de los más grandes, han crecido más que el sujeto 10. Si estas interacciones son lo suficientemente relevantes, el ajuste de este modelo mostrará suficientes mejoras respecto del modelo más simple que compensarán la mayor complejidad de este modelo necesariamente, y por lo tanto, elegiremos este antes que los modelos sencillos propuestos anteriormente. Este se expresa tal que:

$$\text{height}_{ij} = \beta_0 + \beta_1 \cdot \text{age}_i + u_{0j} + u_{1j} \cdot \text{age}_i + \epsilon_{ij}$$

Donde,

- β_0 : Intercepto fijo.
- β_1 : Efecto fijo de **age**.
- u_{0j} : Efecto aleatorio del intercepto para el sujeto j , donde $u_{0j} \sim N(0, \sigma_{u0}^2)$.
- u_{1j} : Pendiente aleatoria correlacionada con **age**, donde $(u_{0j}, u_{1j}) \sim N(0, \Sigma)$, siendo Σ la matriz de covarianza.
- ϵ_{ij} : Error residual, donde $\epsilon_{ij} \sim N(0, \sigma^2)$.

```
# MODELO 3
# Efecto fijo: age
# Efecto aleatorio: intercepto aleatorio + pendiente aleatoria (correlacionados)
mod3 <- lmer(height ~ age + (1 + age|Subject) , Oxboys)
summary(mod3)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: height ~ age + (1 + age | Subject)
## Data: Oxboys
##
## REML criterion at convergence: 724.1
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.65092 -0.57493 -0.02843  0.59605  2.60497
##
## Random effects:
## Groups Name Variance Std.Dev. Corr
## Subject (Intercept) 65.3041  8.0811
##      age      2.8248  1.6807  0.64
## Residual      0.4355  0.6599
## Number of obs: 234, groups: Subject, 26
##
## Fixed effects:
##              Estimate Std. Error      df t value Pr(>|t|)
## (Intercept) 149.3718      1.5854 24.9998  94.22  <2e-16 ***
## age          6.5255      0.3363 24.9989  19.40  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## Correlation of Fixed Effects:
##      (Intr)
## age 0.628
```

En este, el resumen del modelo presenta como el efecto fijo de age es significativo y positivo, así como en los anteriores. Existe variabilidad entre sujetos tanto en el intercepto como en la pendiente, sugiriendo que los sujetos tienen diferentes niveles iniciales de altura y diferentes tasas de crecimiento. La correlación positiva de 0.64 entre el intercepto y la pendiente indica que los individuos con alturas iniciales más altas tienden a crecer más rápido.

• Cuarto modelo

Pasamos al cuarto modelo, en el que ya no tenemos la edad estandarizada como efecto fijo, si no que tenemos la variable “**Occasion**”. Respecto a los efectos aleatorios estarán compuestos únicamente por los interceptos aleatorios para cada sujeto, siendo el modelo más simple junto con el primer modelo ajustado. Por lo tanto, se expresa de la siguiente manera:

$$\text{height}_{ij} = \beta_0 + \beta_1 \cdot \text{Occasion}_i + u_{0j} + \epsilon_{ij}$$

Donde,

- β_0 : Intercepto fijo.
- β_1 : Efecto fijo de **Occasion**.
- u_{0j} : Efecto aleatorio del intercepto para el sujeto j , donde $u_{0j} \sim N(0, \sigma_{u0}^2)$.
- ϵ_{ij} : Error residual, donde $\epsilon_{ij} \sim N(0, \sigma^2)$.

```
# MODELO 4
# Efecto fijo: occasion
# Efecto aleatorio: intercepto aleatorio por cada sujeto
mod4 <- lmer(height ~ Occasion + (1|Subject), Oxboys)
summary(mod4)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: height ~ Occasion + (1 | Subject)
##      Data: Oxboys
##
## REML criterion at convergence: 941.7
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.2916 -0.6364 -0.1662  0.5987  2.3941
##
## Random effects:
##      Groups   Name      Variance Std.Dev.
##      Subject (Intercept) 65.540   8.096
##      Residual              1.709   1.307
## Number of obs: 234, groups: Subject, 26
##
## Fixed effects:
##              Estimate Std. Error      df t value Pr(>|t|)
```

```
## (Intercept) 141.3492      1.5986  25.5444   88.42   <2e-16 ***
## Occasion      1.6341      0.0331 207.0000   49.37   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##      (Intr)
## Occasion -0.104
```

En esta ocasión podemos observar como la altura aumenta en promedio 1.63 cm por cada unidad adicional de la ocasión, lo que refleja un crecimiento constante en el tiempo. Respecto el efecto aleatorio, existe variabilidad significativa entre sujetos en sus alturas iniciales, con una varianza de 65.540. Además, cabe señalar que la variabilidad no explicada por el modelo es 1.709, lo que indica que el modelo captura una parte considerable de la variabilidad en los datos.

• Quinto modelo

Respecto el quinto modelo, continua con la variable referente a la ocasión como efecto fijo y los efectos aleatorios pasan a estar compuestos por los interceptos aleatorios de los sujetos así como por la pendiente, todo y que estos no están correlacionados entre sí. Se expresa tal que:

$$\text{height}_{ij} = \beta_0 + \beta_1 \cdot \text{Occasion}_i + u_{0j} + u_{1j} \cdot \text{Occasion}_i + \epsilon_{ij}$$

Donde,

- β_0 : Intercepto fijo.
- β_1 : Efecto fijo de `Occasion`.
- u_{0j} : Efecto aleatorio del intercepto para el sujeto j , donde $u_{0j} \sim N(0, \sigma_{u_0}^2)$.
- u_{1j} : Pendiente aleatoria no correlacionada con `Occasion`, donde $u_{1j} \sim N(0, \sigma_{u_1}^2)$.
- ϵ_{ij} : Error residual, donde $\epsilon_{ij} \sim N(0, \sigma^2)$.

```
# MODELO 5
# Efecto fijo: occasion
# Efecto aleatorio: intercepto aleatorio + pendiente aleatoria (no correlacionados)
mod5 <- lmer(height ~ Occasion + (1|Subject) + (0 + Occasion|Subject) , Oxboys)
summary(mod5)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: height ~ Occasion + (1 | Subject) + (0 + Occasion | Subject)
##      Data: Oxboys
##
## REML criterion at convergence: 727.4
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -3.03971 -0.55631  0.02501  0.60331  2.32789
##
## Random effects:
##      Groups      Name      Variance Std.Dev.
##      Subject      (Intercept) 48.7357   6.9811
```

```
## Subject.1 Occasion      0.1793  0.4234
## Residual                0.4235  0.6507
## Number of obs: 234, groups: Subject, 26
##
## Fixed effects:
##           Estimate Std. Error      df t value Pr(>|t|)
## (Intercept) 141.34915    1.37224  25.00393   103.0   <2e-16 ***
## Occasion      1.63405     0.08465  25.00376    19.3   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##           (Intr)
## Occasion -0.012
```

En este caso, la altura continua aumentando en promedio 1.63 cm, todo y que existen diferencias respecto los efectos aleatorios. Existe una importante variabilidad en los interceptos entre los sujetos, con una varianza de 48.7357, mientras la variabilidad en las pendientes es menor pero aún relevante. Cabe señalar que el modelo deja una pequeña porción de variabilidad no explicada (0.4235).

• Sexto modelo

Finalmente, el último modelo es ajustado a partir de definir la variable referente a la ocasión como efecto fijo; así como los interceptos aleatorios y pendientes como efectos aleatorios. A diferencia del modelo anterior, este contiene los interceptos aleatorios y las pendientes correlacionadas entre sí. El último modelo se expresa de la siguiente manera:

$$\text{height}_{ij} = \beta_0 + \beta_1 \cdot \text{Occasion}_i + u_{0j} + u_{1j} \cdot \text{Occasion}_i + \epsilon_{ij}$$

Donde,

- β_0 : Intercepto fijo.
- β_1 : Efecto fijo de `Occasion`.
- u_{0j} : Efecto aleatorio del intercepto para el sujeto j , donde $u_{0j} \sim N(0, \sigma_{u0}^2)$.
- u_{1j} : Efecto aleatorio de la pendiente asociado a `Occasion`, correlacionado con u_{0j} . Se asume que:

$$\begin{pmatrix} u_{0j} \\ u_{1j} \end{pmatrix} \sim N\left(0, \begin{bmatrix} \sigma_{u0}^2 & \sigma_{u01} \\ \sigma_{u01} & \sigma_{u1}^2 \end{bmatrix}\right)$$

- ϵ_{ij} : Error residual, donde $\epsilon_{ij} \sim N(0, \sigma^2)$.

```
# MODELO 6
# Efecto fijo: occasion
# Efecto aleatorio: intercepto aleatorio + pendiente aleatoria (correlacionados)
mod6 <- lmer(height ~ Occasion + (1 + Occasion|Subject) , Oxboys)
summary(mod6)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: height ~ Occasion + (1 + Occasion | Subject)
## Data: Oxboys
```

```
##
## REML criterion at convergence: 722.2
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -3.0408 -0.5560  0.0317  0.5899  2.3029
##
## Random effects:
##   Groups   Name                Variance Std.Dev. Corr
##   Subject  (Intercept) 48.2446  6.9458
##             Occasion    0.1774  0.4212  0.44
##   Residual                0.4240  0.6512
## Number of obs: 234, groups: Subject, 26
##
## Fixed effects:
##              Estimate Std. Error      df t value Pr(>|t|)
## (Intercept) 141.34915    1.36535   24.99863   103.5 <2e-16 ***
## Occasion     1.63405     0.08423   24.99784    19.4 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##          (Intr)
## Occasion 0.423
```

En este caso, una vez más la altura continua aumentando en promedio lo mismo que en los modelos ajustados para **Occasion** explicados previamente; así como la variabilidad entre sujetos. No obstante, se presenta una correlación positiva de 0.44 entre los interceptos y pendientes, parece ser que los individuos con alturas iniciales más altas tienden a mostrar un crecimiento más pronunciado conforme aumento “**Occasion**”. Además, la variabilidad residual disminuye, indicando que el modelo ajusta bastante bien los datos.

COMPARACIÓN DE MODELOS

Una vez definidos los seis modelos estudiados, ¿cual de ellos es el más óptimo para nuestros datos? A continuación, los comparamos para así quedarnos con el que mejor se acople a nuestros datos.

Para ello, primero debemos saber que es mejor si tener la variable “**age**” como efecto fijo o la variable “**Occasion**”. Par ello, realizaremos un anova para cada uno de los dos modelos más simples con diferentes efectos fijos y veremos cuál es el mejor.

```
anova(mod1) # Variable age como efecto fijo
anova(mod4) # Variable Occasion como efecto fijo

## Type III Analysis of Variance Table with Satterthwaite's method
##      Sum Sq Mean Sq NumDF DenDF F value    Pr(>F)
## age 4163.6  4163.6      1    207  2423.4 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## Type III Analysis of Variance Table with Satterthwaite's method
##      Sum Sq Mean Sq NumDF DenDF F value    Pr(>F)
## Occasion 4165.4  4165.4      1    207  2436.9 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Según los resultados, ambos muestran el mismo p-valor, indicándonos que cada variable por separado implican un efecto significativo en la variable respuesta. Por lo tanto, nos quedaremos con aquella que resulte más simple. Dado que la variable “Occasion” ha sido creada a partir de la variable “age”, es lógico pensar que lo más simple es no tener que crearla y emplear la variable referente a la edad estandarizada como efecto fijo.

Por lo tanto, de entre los seis modelos creados en el apartado anterior podemos deducir mediante lo realizado que el más óptimo está entre los tres primeros. Por ello, a continuación, compararemos los tres primeros modelos definidos para ver si presentan diferencias significativas entre ellos, y así deducir cuál de entre los tres es el más óptimo.

```
anova(mod1, mod2, mod3)

## Data: Oxboys
## Models:
## mod1: height ~ age + (1 | Subject)
## mod2: height ~ age + (1 | Subject) + (0 + age | Subject)
## mod3: height ~ age + (1 + age | Subject)
##      npar    AIC    BIC logLik deviance   Chisq Df Pr(>Chisq)
## mod1     4 948.57 962.39 -470.28   940.57
## mod2     5 749.02 766.30 -369.51   739.02 201.550  1 < 2.2e-16 ***
## mod3     6 737.97 758.70 -362.98   725.97  13.052  1  0.000303 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Al comparar los tres primeros modelos, se observa que el primer modelo, el cual incluye únicamente un **intercepto aleatorio por sujeto**, presenta los valores más elevados de **AIC** y **BIC**, así como la **log-verosimilitud** más baja (es decir, un valor negativo más extremo). Esto indica que es el modelo con el peor ajuste.

El segundo modelo, que incorpora además una **pendiente aleatoria no correlacionada con el intercepto**, mejora significativamente el ajuste en comparación con el primero. Esto se confirma por un **p-valor inferior a 0.05**, lo que sugiere con un **95% de confianza** que existen **diferencias significativas** entre ambos modelos y que el segundo modelo tiene un mejor rendimiento.

Por otro lado, el tercer modelo añade una **pendiente aleatoria correlacionada** con el intercepto, lo cual supone una mejora adicional respecto al segundo modelo, aunque en menor magnitud que la observada entre el primero y el segundo. Nuevamente, el **p-valor es inferior a 0.05**, lo que nos permite afirmar con un **nivel de significancia del 5%** que las diferencias entre el segundo y el tercer modelo son **estadísticamente significativas**.

En conclusión, el **tercer modelo** es el que proporciona el **mejor ajuste**, al lograr los valores más bajos de **AIC** y **BIC** y una mejora significativa en la log-verosimilitud con respecto a los modelos anteriores.

ANÁLISIS ADICIONAL

Tras los análisis iniciales de comparación, realizamos un estudio adicional para determinar qué metodología de modelo resulta más adecuada para nuestros datos. Compararemos dos enfoques principales:

- **Modelos condicionales:** Incluyen efectos aleatorios (matriz tipo G). Estos son los modelos definidos hasta ahora, de los cuales hemos concluido que el mejor es el tercer modelo.
- **Modelos marginales:** Se basan en estructuras de covarianza (matriz tipo R). Modelo que definiremos a continuación, aplicando lo que ya hemos deducido previamente, así como que el intercepto aleatorio y las pendientes están correlacionadas.

Por lo tanto, con el objetivo de validar la elección del modelo condicional, realizamos un análisis adicional utilizando un modelo GLS, una metodología marginal que permite modelar estructuras de covarianza

específicas. Estos modelos se suelen aplicar en casos donde hay múltiples observaciones de un mismo sujeto en distintos tiempos, lo que introduce correlación entre ellas. En nuestro caso, tenemos diferentes medidas de alturas que se han tomado en diferentes tiempos para cada uno de los 26 niños que componen nuestros datos. Por lo tanto, a continuación ajustaremos un modelo GLS, para ver si el que de momento es nuestro mejor modelo se puede llegar a mejorar. Este se define de la siguiente manera:

```
mod5 <- gls( height ~ age,
              weights = varIdent( form = ~ 1|Subject),
              correlation = corSymm( form= ~ 1|Subject/age),
              data= Oxboys)
summary(mod5)
```

```
## Generalized least squares fit by REML
## Model: height ~ age
## Data: Oxboys
##      AIC      BIC    logLik
## 1403.899 1500.408 -673.9496
##
## Uninitialized correlation structure of class corSymm
## Variance function:
## Structure: Different standard deviations per stratum
## Formula: ~1 | Subject
## Parameter estimates:
##      10      26      25      9      2      6      7
## 1.00000000 0.62580506 0.57378684 0.61827592 0.39419972 0.22131538 0.24279032
##      17      16      15      8      20      1      18
## 0.39062714 0.18079145 0.32469017 0.13376313 0.07083629 0.14228970 0.02747999
##      5      23      11      21      3      24      22
## 0.03750096 0.03007686 0.08129957 0.05856224 0.22628848 0.11302517 0.17941648
##      12      13      14      19      4
## 0.27686640 0.25377652 0.41117262 0.65523221 0.67906790
##
## Coefficients:
##              Value Std.Error   t-value p-value
## (Intercept) 151.0484 0.1082925 1394.8179      0
## age          6.5052 0.1674377  38.8515      0
##
## Correlation:
##      (Intr)
## age -0.035
##
## Standardized residuals:
##      Min      Q1      Med      Q3      Max
## -1.5133067 -1.0120135 -0.6687637  0.8654753  2.0367596
##
## Residual standard error: 20.93071
## Degrees of freedom: 234 total; 232 residual
```

En los resultados obtenidos, observamos lo siguiente:

- Las **varianzas heterogéneas** estimadas muestran diferencias significativas entre los niveles de “age”, confirmando que la varianza no es constante (heterocedasticidad).
- La **estructura de correlación simétrica** capta la dependencia entre medidas repetidas dentro de los sujetos, lo que respalda la inclusión de la variable “Subject/age” en el argumento **correlation**.

- El coeficiente estimado para “age” ($\beta_1 = 6.57$) indica un crecimiento promedio de la altura de 6.57 unidades por cada incremento unitario en la edad. El intercepto ($\beta_0 = 149.38$) representa la altura promedio inicial cuando age = 0.

No obstante, si nos fijamos en los valores AIC y BIC, estos son significativamente superiores en este último modelo en comparación con el tercer modelo definido. De la misma manera, la **log-verosimilitud** es más baja (es decir, un valor negativo más extremo), indicando que el sexto modelo definido, el modelo marginal, tiene un peor ajuste. Por otro lado, también cabe destacar que la variabilidad residual es superior, lo que sugiere que este modelo explica menos variabilidad que el anterior. Por lo tanto, nuestros datos parecen no ser, finalmente, adecuados al tipo de modelo marginal definido, por lo que continuamos teniendo como el mejor modelo el tercero definido, un modelo condicional.

VALIDACIÓN DEL MODELO FINAL

Una vez identificado el mejor modelo, estudiamos su validez. Para ello debemos evaluar:

- El ajuste general del modelo
- La significancia de los efectos fijos
- La estimación de las componentes de varianza
- La correlación entre los efectos aleatorios
- Verificar tanto la normalidad como la homocedasticidad e independencia de los residuos.

Primero, calculamos el R^2 marginal (únicamente efectos fijos) y el R^2 condicional (efectos fijos + aleatorios) para evaluar el **ajuste general del modelo**.

```
r2 <- r2(mod3); r2
```

```
## # R2 for Mixed Models
##
##   Conditional R2: 0.995
##   Marginal R2: 0.210
```

En estos podemos observar una significativa diferencia entre ambos, indicando que el 99.5% de la variabilidad total del modelo es explicada cuando se consideran tanto los efectos fijos como los aleatorios, mientras que un 21% es explicada únicamente por los efectos fijos; lo que destaca la importancia de los efectos aleatorios en el modelo.

A continuación, evaluamos la **significancia de los efectos fijos** mediante los p-valores para cada efecto en el modelo.

```
summary(mod3)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: height ~ age + (1 + age | Subject)
##   Data: Oxboys
##
## REML criterion at convergence: 724.1
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.65092 -0.57493 -0.02843  0.59605  2.60497
##
## Random effects:
##   Groups   Name                Variance Std.Dev. Corr
##   Subject  (Intercept) 65.3041   8.0811
```

```
##           age           2.8248  1.6807  0.64
## Residual           0.4355  0.6599
## Number of obs: 234, groups: Subject, 26
##
## Fixed effects:
##           Estimate Std. Error      df t value Pr(>|t|)
## (Intercept) 149.3718     1.5854  24.9998   94.22  <2e-16 ***
## age         6.5255      0.3363  24.9989   19.40  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##      (Intr)
## age 0.628
```

En este podemos observar, como ya habíamos comentado anteriormente, que la variable “age” aporta información importante al modelo, dado que su coeficiente estimado (6.5255) es estadísticamente significativo con un p-valor inferior a 0.05, lo que indica una relación positiva clara entre la edad y la altura. Además, su pequeño error estándar (0.3363) y el elevado valor t (19.40) respaldan la robustez de esta estimación.

Para verificar **las varianzas de los efectos aleatorios, así como la correlación entre estos**, realizamos lo siguiente:

```
VarCorr(mod3)
0.65989^2
```

```
## Groups Name Std.Dev. Corr
## Subject (Intercept) 8.08109
## age 1.68071 0.641
## Residual 0.65989
## [1] 0.4354548
```


Tanto la desviación estándar del intercepto como la de la pendiente nos indican que existe variabilidad tanto en la altura de los niños, como en las diferentes edades en las que los miden, lo que justifica la inclusión de ambos.

La correlación entre estos es positiva, lo que nos hace deducir que los niños que comienzan con una altura inicial más alta tienden a tener un cambio más rápido a lo largo de sus edades, mientras que los que tienen una altura inicial más baja, como el sujeto 10, tienden a experimentar un crecimiento más lento.

En otras palabras, las componentes de varianza y la correlación entre los efectos aleatorios respaldan la validez del modelo, ya que, una vez más, se ha hecho visible la importancia de añadir tanto el intercepto como la pendiente aleatoria, ambos correlacionados.

Finalmente, realizaremos **dos gráficos para verificar la normalidad, homocedasticidad e independencia de los residuos**.

```
par(mfrow = c(1,2))
qqnorm(residuals(mod3))
qqline(residuals(mod3))
plot(fitted(mod3), residuals(mod3), main = "Valores ajustados vs Residuos")
abline(h = 0, col = "red", lty = 2)
```



Por un lado, en el gráfico de la izquierda, observamos cómo los residuos se acoplan significativamente bien a la línea, aunque presenciamos ciertas desviaciones pequeñas en las colas. Mientras, en el gráfico de la derecha, la aglomeración de puntos alrededor de la línea roja y el hecho de no identificar ningún patrón claro en forma de curva o abanico nos hacen deducir que se cumple tanto el supuesto de homocedasticidad (varianza constante) como el de independencia residual respectivamente.

En conclusión, podemos afirmar la validez del modelo, ya que mediante la evaluación del ajuste general y las estimaciones de varianza de los efectos aleatorios, así como la correlación entre estos, son significativos y justifican la inclusión de los efectos. Además, hemos comprobado que, efectivamente, los efectos fijos son significativos y que se cumplen los supuestos de normalidad, homocedasticidad e independencia residual. Al cumplirse estas últimas suposiciones, se pueden modelar a partir de su promedio y su varianza. Como esta suposición se verifica, no es necesario llevar a cabo un estudio a través de modelos mixtos generalizados para datos de familias no normales.

INTERPRETACIÓN EFECTOS ALEATORIOS

Finalmente, interpretaremos los efectos aleatorios del mejor modelo ajustado, del cual ya hemos comprobado su validez. Al tener una única variable como efecto fijo, esta ha sido interpretada en varias ocasiones a lo largo del estudio (la altura aumenta en aproximadamente 6.52 cm por cada unidad de incremento en la edad estandarizada). Por lo tanto, en esta última sección nos centraremos en interpretar los efectos aleatorios.

```
ranef(mod3)
```

```
## $Subject
##   (Intercept)      age
## 10 -19.0972480 -2.78657081
## 26 -11.3676000 -0.97473776
## 25 -10.1595528 -2.42701922
## 9  -11.2213335 -0.58068709
## 2   -6.5096278 -1.07136150
## 6   -2.5902385 -2.41771807
## 7   -3.2473131 -1.46379318
## 17  -6.3744848  1.89444126
```

```

## 16 -1.8344700 -1.86707137
## 15 -5.0856369 0.51526371
## 8 -1.0776202 -0.06615497
## 20 2.0850840 -1.99240074
## 1 -1.2464286 0.59919330
## 18 1.8031922 -0.51486761
## 5 2.0531170 -0.24308178
## 23 1.6937341 0.63140828
## 11 0.6839701 1.85733347
## 21 1.1525542 0.91894394
## 3 6.2613007 -1.58181452
## 24 3.7645670 0.25652666
## 22 5.1957591 1.50551687
## 12 7.4308035 0.52297437
## 13 6.7004368 1.89757961
## 14 10.0986013 2.09367063
## 19 15.1957042 2.50719744
## 4 15.6927300 2.78722908
##
## with conditional variances for "Subject"

```

Los resultados muestran las desviaciones individuales de cada sujeto respecto a los efectos fijos del modelo mod3. Estas desviaciones permiten analizar la variabilidad en el intercepto (altura inicial) y en la pendiente asociada a la edad (age), mostrando cómo cada sujeto difiere de la tendencia general estimada por el modelo.

En primer lugar, observamos sujetos con interceptos negativos, lo que indica que comienzan con alturas por debajo del promedio. Un ejemplo claro es el sujeto 10, que presenta una desviación en el intercepto de -19.097 y una pendiente de -2.7866, sugiriendo no solo una altura inicial considerablemente menor, sino también una tasa de crecimiento más lenta. De manera similar, el sujeto 26 muestra un intercepto de -11.3676 y una pendiente de -0.9747, lo que confirma un patrón similar, aunque menos extremo.

Por otro lado, encontramos sujetos con interceptos positivos, que inician con alturas superiores al promedio y, en algunos casos, además muestran tasas de crecimiento más elevadas. Por ejemplo, el sujeto 4 tiene un intercepto de 15.6927 y una pendiente de 2.7872, lo que indica que comienza con una altura muy superior a la media y crece a un ritmo más rápido. Un comportamiento similar se observa en el sujeto 15, con un intercepto de 15.1957 y una pendiente de 2.5071.

En contraste, hay sujetos cuyas desviaciones son muy cercanas a cero, lo que implica que su comportamiento se ajusta estrechamente a la tendencia general del modelo. Por ejemplo, el sujeto 6 presenta un intercepto de -0.0776 y una pendiente de -0.0661, lo que sugiere que sus valores son prácticamente idénticos a los efectos fijos estimados.

En términos generales, estos resultados muestran la variabilidad individual en la altura inicial y en las tasas de crecimiento entre los sujetos. Los sujetos con interceptos negativos tienden a comenzar con alturas más bajas y, a menudo, muestran tasas de crecimiento más lentas, mientras que aquellos con interceptos positivos inician con alturas más altas y, en muchos casos, experimentan un crecimiento más acelerado. La presencia de estos efectos aleatorios respalda la importancia de incluir tanto interceptos como pendientes aleatorias en el modelo, ya que permiten capturar de manera adecuada las diferencias individuales entre sujetos.

En conclusión, la interpretación de los efectos aleatorios pone de manifiesto que existen patrones diferenciados en la evolución de la altura con la edad, lo que refleja la variabilidad entre los individuos y justifica el ajuste del modelo mixto propuesto.

CONCLUSIÓN

En este trabajo hemos abordado el análisis de datos longitudinales utilizando modelos lineales mixtos, una metodología que permite capturar tanto la tendencia poblacional (efectos fijos) como la variabilidad individual entre sujetos (efectos aleatorios). A través de una comparación sistemática de modelos, hemos seleccionado el modelo más adecuado, que incluye interceptos y pendientes aleatorias correlacionadas, y que logra describir de manera precisa el crecimiento de la altura en función de la variable “age” (edad estandarizada).

Los principales hallazgos del estudio son los siguientes:

- La variable “age” se confirma como el predictor más relevante del crecimiento, mostrando un efecto positivo y significativo sobre la altura. Por cada unidad de incremento en la edad, se observa un aumento promedio consistente en la altura de los sujetos.
- La inclusión de efectos aleatorios demuestra ser fundamental para capturar las diferencias individuales entre los sujetos, tanto en el punto inicial de altura (intercepto) como en la tasa de crecimiento (pendiente). La correlación positiva entre ambos efectos sugiere que los individuos con alturas iniciales más altas tienden a presentar un crecimiento más rápido, mientras que aquellos con alturas iniciales más bajas muestran una menor tasa de crecimiento.

Adicionalmente, hemos realizado un análisis complementario mediante un modelo marginal (GLS) para validar la robustez de los resultados obtenidos. Aunque este enfoque ofrece una alternativa interesante, los valores de AIC, BIC y log-verosimilitud confirman que el modelo mixto seleccionado proporciona un ajuste superior y, por lo tanto, es el más adecuado para describir nuestros datos.

En conclusión, este trabajo ofrece un análisis riguroso y completo que no solo identifica la variable clave que explica el crecimiento de la altura, sino que también demuestra la importancia de considerar las diferencias individuales en estudios longitudinales. La metodología aplicada y las conclusiones obtenidas proporcionan una base sólida para futuros estudios que busquen modelar datos con estructuras similares.